

FPI

La codificación de caracteres es el sistema que permite representar letras, números, símbolos mediante números para que la computadora pueda entenderlos, ya que solo trabaja con valores binarios (0 y 1).

~~Antes~~ Antes de que existiera un estándar universal, cada fabricante de computadoras inventaba su propia manera de representar letras y números. Intercambiar texto entre sistemas distintos era un caos, lo que una máquina escribía, otro lo leía como basura. Para resolver este problema, en 1963 el American National Standards Institute (ANSI) publicó el estándar ASCII.

ASCII (American Standard Code for Information Interchange) nació pensado para comunicaciones telegráficas y fue adoptado rápidamente por la industria informática. Usaba 7 bits para representar 128 caracteres: letras mayúsculas y minúsculas del inglés, dígitos del 0 al 9, signos de puntuación y algunos caracteres de control como el salto de

El problema surgió cuando la computación se volvió global. Los idiomas europeos necesitaban tilde y acentos, el árabe, el hebreo, el chino y el japonés tenían caracteres completamente distintos.

Durante los años 70 y 80 aparecieron decenas de estándares regionales: ISO 8859-1 para Europa Occidental, ISO 8859-5 para cirílico, entre muchos otros. Cada región resolvía su problema por su cuenta, pero el caos de incompatibilidades seguía creciendo.

La solución llegó en 1991 con la ~~información~~ fundación del Consorcio Unicode, que publicó un mapa universal de caracteres: un número único para cada símbolo de todos los idiomas del mundo.

Sin embargo, Unicode por sí solo no define cómo guardar esos números en un archivo; para eso nacieron las codificaciones UTF (Unicode Transformation Format). UTF-16 apareció en 1996 y UTF-8, diseñado por Ken Thompson y Rob Pike en 1992, fue estandarizado como RFC 3629 en 2003. Con la explosión de Internet, UTF-8 se convirtió rápidamente en el estándar dominante de la web.

¿Cómo funciona?

ASCII: Funciona de la manera más directa posible: asigna a cada carácter un número fijo entre 0 y 127, almacenado siempre en 1 byte. Por ejemplo: la letra 'A' es el número 65 (01000001 en binario), y la 'a' minúscula es el 97. Su simplicidad es su mayor virtud, pero también su limitación: solo puede representar 128 caracteres.

UTF-8: Es una codificación de longitud variable: un carácter puede ocupar entre 1 y 4 bytes dependiendo de su complejidad. Los primeros 128 caracteres (los de ASCII) se representan exactamente igual al que en ASCII, en 1 solo byte. Los caracteres con tilde o la ñ ocupan 2 bytes. Los caracteres del chino, japonés y coreano usan 3 bytes. Y los emojis modernos o caracteres históricos muy raros pueden llegar a 4 bytes. Esta estructura es ingeniosamente robusta: si se ~~puede~~ pierde un byte en una transmisión, el sistema puede detectarlo fácilmente porque los bytes de inicio y los de continuación tienen patrones binarios distintos y reconocibles.

UTF-16: Usa 2 bytes por carácter para la gran mayoría de los idiomas modernos (el llamado Plano Multilingüe Básico), y 4 bytes para caracteres más especiales mediante lo que se llama "pares sustitutos". Tiene una complicación adicional: necesita un marcador especial al inicio del archivo, el BOM (Byte Order Mark), para indicar si los bytes están ordenados de mayor a menor (big-endian) o al revés (little-endian), ya que el orden importa cuando se trabaja con unidades de 16 bits.

¿Por qué es útil la codificación de caracteres?

UTF-8 resolvió el problema más grande: que un solo estándar funcionara para todos los idiomas del mundo sin romper lo que ya existía. Gracias a él, una misma página web puede mostrar español, árabe, chino y emojis sin conflictos. UTF-16, por su parte, es especialmente útil en sistemas donde el texto asiático es profundamente representado esos caracteres con menos bytes y ganando así velocidad y eficiencia.

Aplicaciones y Uso

Hoy en día la codificación de caracteres está en todas partes, aunque no la vemos. ASCII sigue siendo la base silenciosa de los comandos de terminal, archivos de configuración y código fuente.

UTF-8. Se utiliza principalmente en páginas web, ya que es el estándar oficial para la codificación en HTML y permite que los sitios muestren correctamente textos en diferentes idiomas y símbolos especiales. También se emplea en aplicaciones móviles y programas de computadora para asegurar que los usuarios pueden escribir y leer caracteres como acentos, la ñ, signos matemáticos o emojis sin errores.

UTF-16. Se utiliza principalmente en algunos sistemas operativos y plataformas de programación. Por ejemplo, es común en aplicaciones desarrolladas con ciertos lenguajes como Java y en entornos como Windows, donde muchos procesos internos manejan texto UTF-16. También se usa en archivos y base de datos que manejen gran cantidad de idiomas.